

实验一 贝叶斯分类器设计与实现

一、实验目的

1. 了解朴素贝叶斯基本原理，掌握朴素贝叶斯分类器的计算方法；
2. 编程实现高斯贝叶斯分类器；
3. 使用高斯贝叶斯分类器实现二分类预测，度量模型性能。

二、实验原理

使用 Python 读取数据集信息并对数据进行预处理，随后使用分类器实现二分类预测，并根据精确率、召回率和 F1 值度量模型性能。

三、实验内容

该实验选取中文外卖评论数据集，该数据集包括外卖订单的评论以及每条评论对应的情感，0 表示消极情感，1 表示积极情感。对评论进行分词、去停用词等数据清洗，用 TF-IDF 算法构建词向量。利用朴素贝叶斯对数据进行训练、效果对比。最后把评论的情感真实值和预测值进行对比。

1、读取数据并进行探索性分析

1.1 导入需要的库

```
import pandas as pd
import jieba
import numpy as np
```

1.2 读取 csv 文件并显示表格

```
pd.read_csv('xxxx/中文外卖评论数据集.csv', encoding='UTF-8')#读取csv文件
```

得到

	label	review
0	1	很快, 好吃, 味道足, 量大
1	1	没有送水没有送水没有送水
2	1	非常快, 态度好。
3	1	方便, 快捷, 味道可口, 快递给力
4	1	菜味道很棒! 送餐很及时!
...	...	...
11982	0	以前几乎天天吃, 现在调料什么都不放,
11983	0	昨天订凉皮两份, 什么调料都没有放, 就放了点麻油, 特别难吃, 丢了一份, 再也不想吃了
11984	0	凉皮太辣, 吃不下都
11985	0	本来迟到了还自己点!!!
11986	0	肉夹馍不错, 羊肉泡馍酱肉包很一般。凉面没想象中好吃。送餐倒是很快。

1.3 查看数据缺失性及重复性

- (1) 查看数据是否缺失 isnull
- (2) 查看数据是否重复 duplicated
- (3) 去除重复数据 drop_duplicates

1.4 绘制情感类别条形图

- (1) 引入绘图包

```
## 绘制条形图
import seaborn as sns
import matplotlib.pyplot as plt
```

- (2) 设置图片大小 figsize= (x,y)
- (3) 设置横纵坐标 sns.countplot(x='label', data=)
- (4) 设置标题及字号 (标题: 姓名+学号, 字号 fontsize=xx)

2、对评论文本进行数据清洗

2.1 加载哈工大停用词表

```
#加载停用词
def stopwordslist(filepath):
    stopwords = [line.strip() for line in open(filepath, 'r', encoding='utf-8').readlines()]
    return stopwords
stopwords = stopwordslist('xxx/Downloads/哈工大停用词表数据集.csv')
```

2.2 建立清洗函数

- (1) 定义清洗函数 def data_cleaning(content_list):
- (2) 建立空列表存放清洗后数据 content_seg = []
- (3) 初始化特殊字符、标点、数字、字母等 symbols = '-\\n~%≥℃|/【】↓#~_「」！? \', 、. ; 。《》() () . — , 0123456789abcdefghijklmnopqrstuvwxyz'

- (4) 初始化停用词表 for content in content_list:
- (5) 去除停用词 for con in content:
- (6) 包含 clearing 则替换为空格 if con in symbols:

content = content.replace(con, '')

- (7) 分词

con_list = jieba.cut(content, cut_all=False)

result_list = []

- (8) 去停用词

for con in con_list:

if con not in stopwords and con!='\n' and con!='\u3000' and

con!=' ':

result_list.append(con)


str1 = ''.join(result_list)

content_seg.append(str1)

(9) 将评论转换为列表

2.3 用清洗函数进行数据清洗

(1) 用数据清洗函数清洗数据并展示得到



'味道 好极 送餐 很快 师傅 辛苦',
'量 大 味道 好 送餐 师傅 都 很 好',
'送餐 师傅 很 好 味道 好极',
'送货 速度 很快 定 这家 赞',
'很 方便 很快 送到 棒',
'好吃 总点 多够 五个人 吃 送 很快',
'很香 很 美味 下次 还会 光顾',
'送餐 特别 快 态度 辛苦',
'服务 很 不错 送到 很快 半小时 不到 送来',
'速度 很快 大雾 霾 天 外卖 骑士 态度 都 很 好 赞赞赞',
'味道 正宗 量 大 内容',
'送餐 非常 快 态度 特别 好 谢谢',
'又快又好 量足 经常 吃',
'好大 一盆 点 小 份量 足',
'配送 人员 态度 好 速度 快',

(2) 将清洗后数据与原数据一同演示['review_clean']=content_seg

(3) 再次查看数据是否缺失

3. 利用 TF-IDF 算法把词语进行向量化

(1) 实现 向 量 化 方 法 from sklearn.feature_extraction.text import

TfidfVectorizer

(2) 用 TfidfVectorizer 把词向量维度设置为 3000

(3) 用 fit_transform 将文本向量化后的数据赋给 data_transform

(4) 将 data_transform 转换为数组 xxx.toarray()

4. 划分训练集和测试集

5. 使用分类器进行训练

(1) 导入高斯贝叶斯函数

(2) 训练、测试

(3) 计算评价指标 precision, recall, f1_score

(4) 高斯贝叶斯分类器在测试集上的准确率为?